Caderno 3
Regressão e análise de variância

Murilo Miguel Narciso

Instituto Militar de Engenharia • 29 de julho de 2026

Este caderno trata o planejamento fatorial do Caderno 2 como um problema de regressão e, a partir dele, constrói o instrumental que permite julgar a qualidade de um modelo ajustado: a decomposição da variância, o coeficiente de determinação e sua versão ajustada, os testes de significância, o valor-p, os diagnósticos de resíduo, a distinção entre falta de ajuste e erro puro, e a validação por PRESS. Boa parte deste conteúdo não tem tratamento direto no acervo de referência desta disciplina: o coeficiente de determinação ajustado aparece em relatórios de software sem definição alguma, o valor-p nunca é definido em português corrente, e a validação cruzada um a um não é mencionada em nenhum documento consultado. Por isso este é o caderno que fecha a maior lacuna do material didático original, e a ênfase recai sobre esses pontos.

Sumário

1 Do efeito ao modelo **2**

2 O modelo linear nos parâmetros **2**

3 Mínimos quadrados: a intuição antes da álgebra **2**

4 Regressão linear simples **4**

5 Decomposição da variância **4**

6 O coeficiente de determinação **5**

7 O coeficiente de determinação ajustado **5**

8 O teto do coeficiente de determinação **6**

9 Testes de significância **7**

10 O valor-p **7**

11 Intervalos de confiança dos coeficientes e da resposta prevista **8**

12 Resíduos e normalidade **8**

13 Falta de ajuste e erro puro **9**

14 PRESS e o R^2 previsto **10**

15 Exemplo de aplicação: a velocidade de queima de uma pólvora **12**

1 Do efeito ao modelo

No Caderno 2, a matriz de planejamento em variáveis codificadas serviu para calcular efeitos por contraste: cada coluna de sinais ± 1 definia uma comparação de médias, e o produto $\mathbf{X}^\top \mathbf{y}$ produzia diretamente as somas que, divididas pelo número de ensaios, geravam os efeitos e os coeficientes. Essa mesma matriz $\mathbf{X}$, entretanto, é também a matriz de regressores de um modelo de regressão linear múltipla. Reconhecer essa identidade é o que permite emprestar da regressão todo o instrumental de inferência (testes de significância, intervalos de confiança, medidas de qualidade de ajuste) para julgar planejamentos fatoriais, em vez de tratá-los como um procedimento de cálculo isolado.

Considere-se o planejamento 2^2 do catalisador, já apresentado no Caderno 2 com os dados de `peixoto-2x2`. Em termos de médias por célula, o vetor de respostas e a matriz de regressores, com a primeira coluna reservada ao intercepto e a terceira à interação $x_1 x_2$, são

$$\mathbf{y} = \begin{bmatrix} 59 \\ 90 \\ 54 \\ 68 \end{bmatrix}, \qquad \mathbf{X} = \begin{bmatrix} 1 & -1 & -1 & +1 \\ 1 & +1 & -1 & -1 \\ 1 & -1 & +1 & -1 \\ 1 & +1 & +1 & +1 \end{bmatrix}. \tag{1}$$

Cada linha de $\mathbf{X}$ é um ensaio; cada coluna, além da primeira, é o contraste que define um efeito. A codificação em ± 1 torna as colunas ortogonais entre si, de modo que $\mathbf{X}^\top \mathbf{X}$ é uma matriz diagonal: $4\,\mathbf{I}_4$ neste caso, com quatro ensaios. É essa propriedade, estabelecida no Caderno 2 a partir da geometria do cubo, que faz cada coeficiente de regressão poder ser calculado isoladamente dos demais, sem que a inclusão ou a remoção de um termo altere a estimativa dos outros. A Seção 3 retoma esta mesma matriz para mostrar, com números, como a fórmula geral de mínimos quadrados reproduz exatamente os efeitos já conhecidos.

2 O modelo linear nos parâmetros

Um modelo é dito linear nos parâmetros quando a resposta é escrita como uma combinação linear de coeficientes desconhecidos, multiplicando funções conhecidas das variáveis de entrada. Em notação matricial,

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}, \tag{2}$$

em que $\mathbf{y}$ reúne as n observações, $\mathbf{X}$ é a matriz de delineamento com p colunas, $\boldsymbol{\beta}$ é o vetor de p parâmetros desconhecidos e $\boldsymbol{\varepsilon}$ é o vetor de erros aleatórios, não observáveis, de média nula e variância σ^2 constante. A exigência de linearidade recai sobre $\boldsymbol{\beta}$, não sobre as variáveis originais: um modelo com termo quadrático, $y_i = \beta_0 + \beta_1 x_i + \beta_2 x_i^2 + \varepsilon_i$, é linear nos parâmetros, porque β_2 multiplica a coluna conhecida x_i^2 da matriz $\mathbf{X}$. O mesmo vale para o modelo de potência que fecha este caderno, em que a linearização por logaritmo transfere toda a não linearidade para dentro das colunas conhecidas de $\mathbf{X}$, deixando os parâmetros para serem estimados por um ajuste inteiramente linear.

O vetor de respostas ajustadas é $\hat{\mathbf{y}} = \mathbf{X}\hat{\boldsymbol{\beta}}$, obtido ao substituir o parâmetro verdadeiro, desconhecido, pela sua estimativa. A diferença entre o modelo geral da Equação (2) e sua versão ajustada é o objeto da seção seguinte.

3 Mínimos quadrados: a intuição antes da álgebra

Antes de qualquer manipulação matricial, vale fixar a imagem que sustenta o método. A Figura 1 apresenta a nuvem de dezoito observações de velocidade de queima de uma pólvora contra a pressão, linearizadas por logaritmo (conjunto `peixoto-potencia`, detalhado por completo na Seção 15), com a reta ajustada e os resíduos desenhados como segmentos verticais entre cada ponto e a reta.

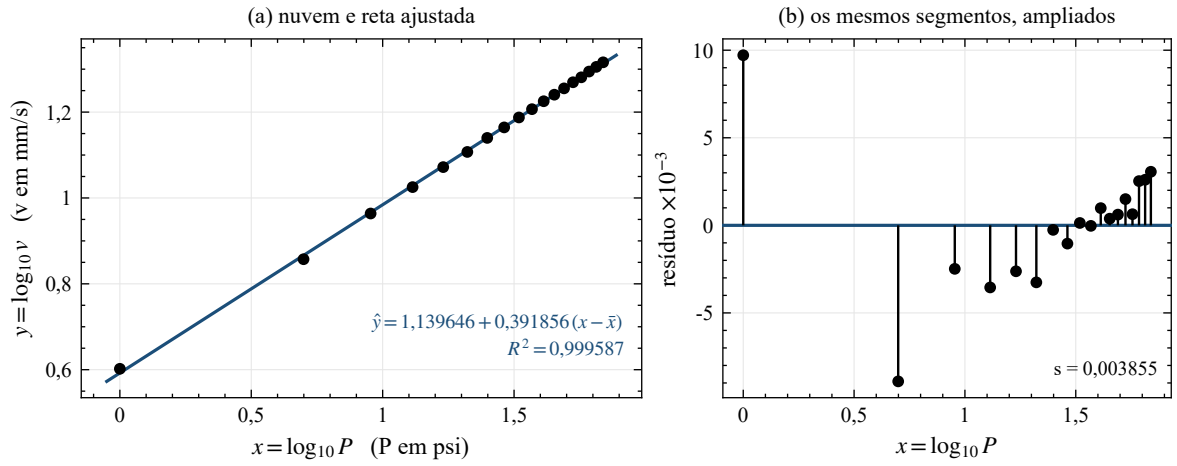


Figura 1. À esquerda, a nuvem de pontos com a reta ajustada por mínimos quadrados. À direita, os mesmos segmentos residuais, ampliados em mil vezes para tornar visível a sua pequena magnitude diante do ajuste quase perfeito ($R^2 = 0{,}999587$). Dados de `peixoto-potencia`.

O critério de mínimos quadrados escolhe, entre todas as retas possíveis, aquela que minimiza a soma dos quadrados desses segmentos verticais, e não a distância perpendicular à reta. A escolha da distância vertical não é arbitrária: o objetivo do ajuste é prever y a partir de x, de modo que o erro relevante é o erro de previsão na escala da resposta, medido ao longo do eixo que a reta pretende explicar. A escolha do quadrado, e não do módulo da distância, garante uma solução única e diferenciável em toda parte, e faz a soma minimizada coincidir exatamente com a soma de quadrados residual que alimenta a análise de variância da Seção 5.

Antes de prosseguir, é necessário distinguir dois objetos que a notação costuma confundir. O erro ε_i da Equação (2) pertence ao modelo verdadeiro e desconhecido: é a distância entre a observação e a reta que a natureza de fato obedece, e nunca é observado. O resíduo $e_i = y_i - \hat{y}_i$, em contraste, é calculado a partir do modelo ajustado, e depende de $\hat{\boldsymbol{\beta}}$, portanto da amostra particular usada na estimação. O resíduo é a melhor estimativa disponível do erro, mas não é o erro: duas amostras diferentes do mesmo processo produzem o mesmo $\boldsymbol{\varepsilon}$ verdadeiro (no sentido distribucional) e resíduos distintos, porque cada amostra estima $\boldsymbol{\beta}$ de forma ligeiramente diferente.

A solução que minimiza $\sum_i e_i^2 = (\mathbf{y} - \mathbf{X}\boldsymbol{\beta})^\top (\mathbf{y} - \mathbf{X}\boldsymbol{\beta})$ em relação a $\boldsymbol{\beta}$ é obtida derivando essa forma quadrática e igualando o gradiente a zero, o que conduz às equações normais $\mathbf{X}^\top\mathbf{X}\boldsymbol{\beta} = \mathbf{X}^\top\mathbf{y}$. Sempre que $\mathbf{X}^\top\mathbf{X}$ é inversível, a solução fecha-se em forma explícita:

$$\hat{\boldsymbol{\beta}} = \left(\mathbf{X}^\top\mathbf{X}\right)^{-1}\mathbf{X}^\top\mathbf{y}. \tag{3}$$

Exemplo de aplicação. Mínimos quadrados no fatorial 2^2

Com a matriz $\mathbf{X}$ e o vetor $\mathbf{y}$ da Equação (1), $\mathbf{X}^\top\mathbf{X} = 4\,\mathbf{I}_4$ em razão da ortogonalidade das colunas, de modo que $(\mathbf{X}^\top\mathbf{X})^{-1} = \frac{1}{4}\mathbf{I}_4$. O vetor $\mathbf{X}^\top\mathbf{y}$ reúne a soma de todas as respostas na primeira posição e, nas demais, a soma de respostas com o sinal de cada coluna: 271, 45, −27 e −17. Aplicando a Equação (3),

$$\hat{\boldsymbol{\beta}} = \tfrac{1}{4}(271,\ 45,\ -27,\ -17)^\top = (67{,}75,\ 11{,}25,\ -6{,}75,\ -4{,}25)^\top,$$

reproduzindo exatamente a média global e os três coeficientes já obtidos no Caderno 2 pela via do contraste. A regressão e o contraste são, para este planejamento, o mesmo cálculo escrito de duas formas.

---

4 Regressão linear simples

No caso de um único regressor, é conveniente escrever o modelo na forma centrada, $y_i = \beta_0 + \beta_1(x_i - \bar{x}) + \varepsilon_i$, com $\bar{x}$ a média das observações de x. A centragem desloca a origem do eixo para o centro da nuvem sem alterar a inclinação da reta, e traz duas vantagens que justificam sua adoção como convenção. Em primeiro lugar, as estimativas de mínimos quadrados assumem forma fechada simples,

$$\hat{\beta}_0 = \bar{y}, \qquad \hat{\beta}_1 = \frac{\sum_i (x_i - \bar{x})\, y_i}{\sum_i (x_i - \bar{x})^2}. \tag{4}$$

Em segundo lugar, a coluna do intercepto (uma coluna de uns) e a coluna do regressor centrado tornam-se ortogonais, exatamente pela mesma razão que tornava ortogonais as colunas do planejamento fatorial codificado: a soma $\sum_i (x_i - \bar{x})$ é nula por construção. Disso decorre que $\hat{\beta}_0$ e $\hat{\beta}_1$ são estatisticamente independentes, com variâncias $\mathrm{Var}(\hat{\beta}_0) = \sigma^2/n$ e $\mathrm{Var}(\hat{\beta}_1) = \sigma^2/\sum_i (x_i - \bar{x})^2$, sem termo de covariância entre elas. É por essa razão que o modelo de potência da Seção 15 é escrito na forma $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1(x - \bar{x})$, com $\hat{\beta}_0 = 1{,}139646$ igual à média das dezoito respostas transformadas, tal como indicado na Figura 1.

5 Decomposição da variância

A soma de quadrados total, que mede a variabilidade de toda a amostra em torno da própria média, decompõe-se em uma parcela atribuível ao modelo e uma parcela residual:

$$\mathrm{SQ_T} = \sum_i (y_i - \bar{y})^2, \qquad \mathrm{SQ_R} = \sum_i (\hat{y}_i - \bar{y})^2, \qquad \mathrm{SQ_r} = \sum_i (y_i - \hat{y}_i)^2, \qquad \mathrm{SQ_T} = \mathrm{SQ_R} + \mathrm{SQ_r}. \tag{5}$$

A identidade da Equação (5) é geométrica e não depende da distribuição dos erros: decorre diretamente de $\hat{y}_i - \bar{y}$ e $y_i - \hat{y}_i$ serem ortogonais entre si, consequência das próprias equações normais que definiram $\hat{\boldsymbol{\beta}}$. Os graus de liberdade seguem a mesma partição, com $n - 1$ para o total, $p - 1$ para a regressão (o número de regressores além do intercepto) e $n - p$ para o resíduo.

A Figura 2 ilustra a decomposição sobre o conjunto `peixoto-lin-quad`, dezoito observações de um mesmo experimento em nove níveis de x com duas réplicas cada, ajustado por uma reta.

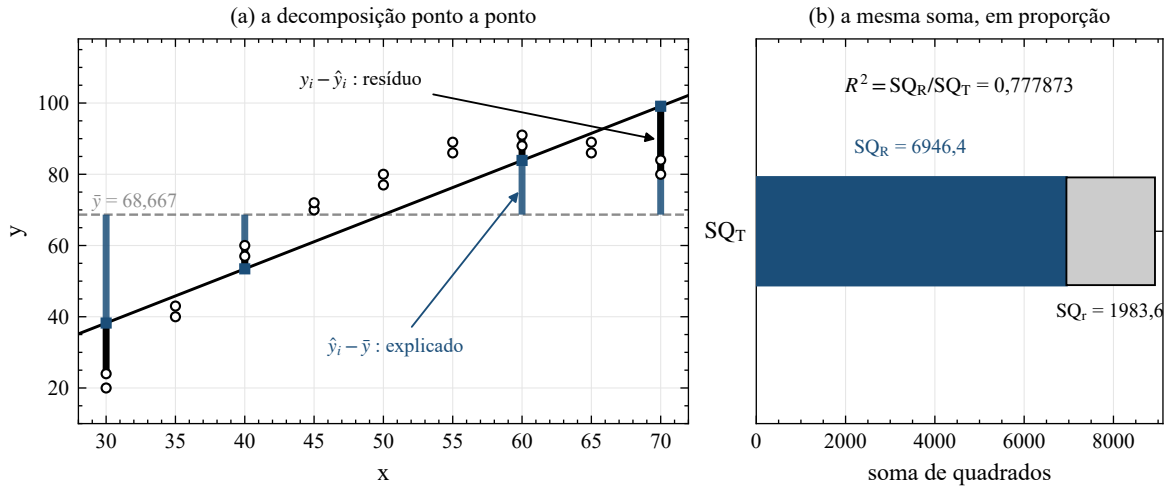


Figura 2. À esquerda, quatro observações escolhidas com a decomposição ponto a ponto entre a parcela explicada, $\hat{y}_i - \bar{y}$, e o resíduo, $y_i - \hat{y}_i$. À direita, a mesma soma de quadrados total representada em proporção, com $\mathrm{SQ_R} = 6.946{,}4$ e $\mathrm{SQ_r} = 1.983{,}6$ somando os $\mathrm{SQ_T} = 8.930{,}0$ do conjunto `peixoto-lin-quad`.

6 O coeficiente de determinação

O coeficiente de determinação é a fração da variabilidade total explicada pelo modelo,

$$R^2 = \frac{\mathrm{SQ_R}}{\mathrm{SQ_T}} = 1 - \frac{\mathrm{SQ_r}}{\mathrm{SQ_T}}. \tag{6}$$

Por construção, $0 \le R^2 \le 1$: o valor 1 corresponde a um ajuste que reproduz exatamente todas as observações, e o valor 0, a um modelo que não explica nada além da própria média. A leitura correta de R^2 é a de proporção de variação explicada, não a de qualidade absoluta do modelo, distinção retomada em detalhe na Seção 8.

Exemplo de aplicação. Análise de variância do modelo linear de `peixoto-lin-quad`

A Tabela 1 sintetiza a decomposição da variância da Figura 2 na forma de uma tabela de análise de variância, com a média quadrática de cada fonte obtida ao dividir a soma de quadrados pelos respectivos graus de liberdade.

Tabela 1. Análise de variância do modelo linear ajustado a `peixoto-lin-quad`, $n = 18$.

Fonte de variação	SQ	GL	MQ
Regressão	6.946,409	1	6.946,409
Resíduo	1.983,592	16	123,9745
Total	8.930,000	17	

A razão entre as duas somas de quadrados fornece $R^2 = 0{,}777873$: cerca de 78% da variação do conjunto é explicada pela reta ajustada. O restante, pouco mais de 22%, permanece no resíduo, e a Seção 13 mostra que essa parcela residual é quase inteiramente falta de ajuste, e não erro experimental.

7 O coeficiente de determinação ajustado

O coeficiente de determinação carrega uma propriedade incômoda: ele nunca diminui com a inclusão de um novo regressor no modelo, mesmo que esse termo seja irrelevante para explicar a resposta. Isso ocorre porque mínimos quadrados, ao acrescentar uma coluna a $\mathbf{X}$, tem à sua disposição um grau de liberdade a mais para reduzir a soma de quadrados residual, e o mínimo de uma soma de quadrados nunca cresce quando o espaço de busca se amplia. Em consequência, R^2 isoladamente não distingue um modelo que melhorou de um modelo que apenas absorveu ruído.

O coeficiente de determinação ajustado corrige esse viés ao penalizar a perda de graus de liberdade do resíduo:

$$R^2_{\mathrm{aj}} = 1 - (1 - R^2) \cdot \frac{n - 1}{n - p}, \tag{7}$$

em que n é o número de observações e p o número de parâmetros do modelo, intercepto incluído. Diferentemente de R^2, R^2_{aj} pode diminuir quando um termo é acrescentado: se a redução em $\mathrm{SQ_r}$ trazida pelo novo regressor for pequena, o fator $(n-1)/(n-p)$ cresce mais depressa do que $(1 - R^2)$ diminui, e o produto aumenta, derrubando R^2_{aj}. É essa propriedade que torna R^2_{aj} útil para comparar modelos com número diferente de termos, papel que R^2 sozinho não cumpre.

Exemplo de aplicação. Um modelo sem poder explicativo, e um que generaliza

A Tabela 2 contrasta dois relatórios de software sobre planejamentos de dois fatores. O conjunto `origin-2x2` ajusta um modelo de efeitos principais a um fatorial 2^2 com duas réplicas; o conjunto `aula-originpro` ajusta o mesmo tipo de modelo a outro fatorial 2^2 com duas réplicas, resposta distinta.

Tabela 2. Coeficiente de determinação e sua versão ajustada em dois relatórios de software.

Conjunto	R^2	R^2_{aj}
`origin-2x2`	0,34312	0,08037
`aula-originpro`	0,866924	0,813693

No primeiro caso, o modelo explica apenas 34% da variação observada, e o valor ajustado, 8%, revela que quase todo esse poder explicativo aparente se deve ao número de parâmetros ajustados, não a uma relação real entre fatores e resposta. É um modelo sem poder explicativo prático, ainda que R^2 isoladamente não denunciasse isso com a mesma clareza. No segundo, R^2 e R^2_{aj} permanecem próximos um do outro, 0,87 contra 0,81, o que indica que o poder explicativo do modelo não depende de forma crítica do número de parâmetros ajustados: é o padrão esperado de um modelo que de fato captura a relação entre fatores e resposta, e ao qual esta narrativa retorna nas Seções 9 e 14.

8 O teto do coeficiente de determinação

Um conceito raramente discutido, e diretamente útil na prática, é o de que R^2 tem um teto imposto pelo próprio ruído experimental, teto que nenhum modelo, por melhor que seja, consegue ultrapassar. Quando existem réplicas genuínas, a soma de quadrados residual nunca pode ficar abaixo da soma de quadrados de erro puro SQ_{ep}, definida no Caderno 1 e retomada na Seção 13 como a variabilidade interna aos pontos replicados, que nenhuma forma funcional consegue reduzir por depender apenas da dispersão entre réplicas. Segue que a fração máxima de variação explicável por qualquer modelo, por mais flexível que seja, é

$$R^2_{\max} = \frac{\text{SQ}_{\text{T}} - \text{SQ}_{\text{ep}}}{\text{SQ}_{\text{T}}}. \tag{8}$$

Exigir de um modelo um R^2 acima desse teto é exigir o impossível: é pedir que o ajuste explique inclusive a variação que é, por definição, ruído puro, sem relação alguma com os fatores controlados. Ensaios com grande variabilidade de medição têm teto baixo, e nenhuma sofisticação de modelo compensa essa limitação; ensaios muito controlados, como o de laboratório de calibração, têm teto próximo de 1, e um R^2 modesto nesse contexto já é sinal de modelo inadequado.

Exemplo de aplicação. O teto de `peixoto-lin-quad`

Para o conjunto `peixoto-lin-quad`, com $\text{SQ}_{\text{T}} = 8.930$ e $\text{SQ}_{\text{ep}} = 45$ obtidos das duas réplicas em cada um dos nove níveis de x, o teto vale

$$R^2_{\max} = \frac{8930 - 45}{8930} = 0{,}994961,$$

isto é, cerca de 99,5%. O modelo quadrático da Seção 13, com $R^2 = 0{,}993461$, aproxima-se desse teto de perto, o que confirma que praticamente toda a variação explicável já foi capturada e que pouco resta a ganhar ao complicar ainda mais o modelo.

9 Testes de significância

Duas perguntas distintas precisam de testes distintos. A primeira, se o modelo como um todo explica uma fração de variação maior do que se explicaria por acaso, responde-se pelo teste F da regressão,

$$F = \frac{\mathrm{MQ_R}}{\mathrm{MQ_r}} = \frac{\mathrm{SQ_R}/(p-1)}{\mathrm{SQ_r}/(n-p)}, \tag{9}$$

comparado ao quantil $F_\alpha(p-1,\, n-p)$ sob a hipótese nula de que todos os coeficientes, exceto o intercepto, são nulos. A segunda pergunta, se um coeficiente específico é diferente de zero, responde-se pelo teste t individual, $t = \hat{\beta}_j / \mathrm{EP}(\hat{\beta}_j)$, com $n - p$ graus de liberdade. Quando o termo testado tem um único grau de liberdade, como um efeito principal em um planejamento fatorial, as duas perguntas coincidem, e $t^2 = F$: o teste t do coeficiente e o teste F daquele termo isolado na tabela de análise de variância são a mesma comparação escrita de duas formas.

Exemplo de aplicação. Um termo relevante, um termo irrelevante

A Tabela 3 retoma os dois conjuntos da Seção 7 e reporta o teste t de cada coeficiente ao lado do teste F equivalente daquele termo na análise de variância, confirmando a identidade $t^2 = F$ em cada linha.

Tabela 3. Testes de significância dos efeitos principais em `origin-2x2` (5 graus de liberdade do erro) e em `aula-originpro` (5 graus de liberdade do erro).

Conjunto	Termo	t	F	p
`origin-2x2`	Fibra	0,38139	0,14546	0,71858
`origin-2x2`	Cimento	−1,57044	2,46628	0,17711
`aula-originpro`	cond	2,93520	8,61538	0,03244
`aula-originpro`	par	4,89460	23,95706	0,00450

Em `origin-2x2`, nenhum dos dois efeitos principais se distingue do ruído a 5%: os valores-p, 0,72 e 0,18, estão muito acima do limiar convencional. Em `aula-originpro`, os dois efeitos são significativos, com valores-p de 0,032 e 0,0045. É o mesmo par de fatores, condição e pressão de compactação, medido em resposta diferente, com conclusões opostas quanto à significância. Vale ainda registrar, como referência de grandeza, que o ajuste de `peixoto-potencia` da Seção 15 produz $F = 38.739{,}5$ para o coeficiente angular, uma ordem de grandeza típica de um ajuste quase determinístico, muito distante da fronteira de significância que separa os dois conjuntos desta tabela.

10 O valor-p

O valor-p é a probabilidade de observar, sob a hipótese nula, uma estatística de teste tão extrema ou mais extrema do que a que foi de fato calculada a partir dos dados. Para o teste t de um coeficiente, é a probabilidade de uma variável t com $n - p$ graus de liberdade exceder, em módulo, o valor observado. Quanto menor o valor-p, menos compatíveis os dados são com a hipótese de que o coeficiente vale zero, e maior a evidência a favor de que o efeito é real.

É igualmente importante fixar o que o valor-p não significa. Ele não é a probabilidade de a hipótese nula ser verdadeira, nem a probabilidade de o efeito estimado ser real, nem uma medida do tamanho ou da relevância prática do efeito. Um efeito pequeno e sem importância pode ter valor-p minúsculo se a amostra for grande o bastante, e um efeito grande pode ter valor-p elevado se a variabilidade do erro experimental for grande ou o número de graus de liberdade, pequeno, como ocorre nos cinco graus de liberdade de `origin-2x2` da Tabela 3: os efeitos de fibra e cimento podem ser reais e ainda assim não se distinguirem do ruído nessa amostra particular.

O limiar de 5%, tão citado na prática, é convenção adotada por Ronald Fisher no início do século XX, e não uma lei da natureza. Nada na matemática do teste distingue 0,049 de 0,051; a diferença de conclusão entre os dois valores é um artefato de onde a convenção traçou a linha, não uma mudança substantiva na evidência. Áreas de decisão que exigem mais cautela, como ensaios clínicos, costumam adotar limiares mais rigorosos; a engenharia de materiais, em contrapartida, frequentemente aceita 10% em etapas de triagem, quando o custo de descartar por engano um fator relevante supera o custo de investigar um fator que depois se revela irrelevante. A escolha do limiar deveria refletir esse balanço de custos, e não ser copiada de um relatório de software sem reflexão.

11 Intervalos de confiança dos coeficientes e da resposta prevista

Cada coeficiente estimado tem um intervalo de confiança da forma $\hat{\beta}_j \pm t_{\alpha/2,\,n-p} \cdot \mathrm{EP}(\hat{\beta}_j)$, com o mesmo quantil t que alimenta o teste da Seção 9. Para a resposta prevista em um ponto x_0, o intervalo se apoia na variância da previsão,

$$\mathrm{Var}(\hat{y}_0) = \mathrm{MQ_r}\left[\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{\sum_i (x_i - \bar{x})^2}\right], \tag{10}$$

que cresce à medida que x_0 se afasta do centro $\bar{x}$ da faixa experimental, por causa do segundo termo entre colchetes. O resultado prático é uma banda de confiança em forma de ampulheta em torno da reta ajustada, estreita perto do centro dos dados e alargando-se nas extremidades. Extrapolar a previsão para além da faixa efetivamente observada amplia essa incerteza sem limite, e a Equação (10) não é válida fora da região onde os dados foram coletados, porque nada garante que a forma funcional ajustada continue apropriada além dela.

Exemplo de aplicação. Precisão dos coeficientes em `peixoto-potencia`

Com dezoito pontos e $n - p = 16$ graus de liberdade, o quantil t a 95% vale 2,119905. Os intervalos de confiança resultantes para os dois coeficientes do modelo centrado são

$$\hat{\beta}_0 = 1{,}139646 \pm 0{,}001926, \qquad \hat{\beta}_1 = 0{,}391856 \pm 0{,}004221,$$

ambos com semi-amplitude bem menor que 1% do valor estimado, reflexo direto do ajuste quase perfeito já anunciado pelo $R^2 = 0{,}999587$ da Figura 1. A pequena magnitude do resíduo, visível apenas quando ampliada em mil vezes no painel (b) daquela figura, é a mesma causa que torna aqui os coeficientes tão precisamente determinados.

12 Resíduos e normalidade

A validade dos testes t e F apoia-se em hipóteses sobre o erro ε_i: média nula, variância constante e distribuição próxima da normal. Como o erro verdadeiro não é observável, essas hipóteses são verificadas por meio do resíduo, sua melhor aproximação disponível, com quatro gráficos de diagnóstico de uso corrente.

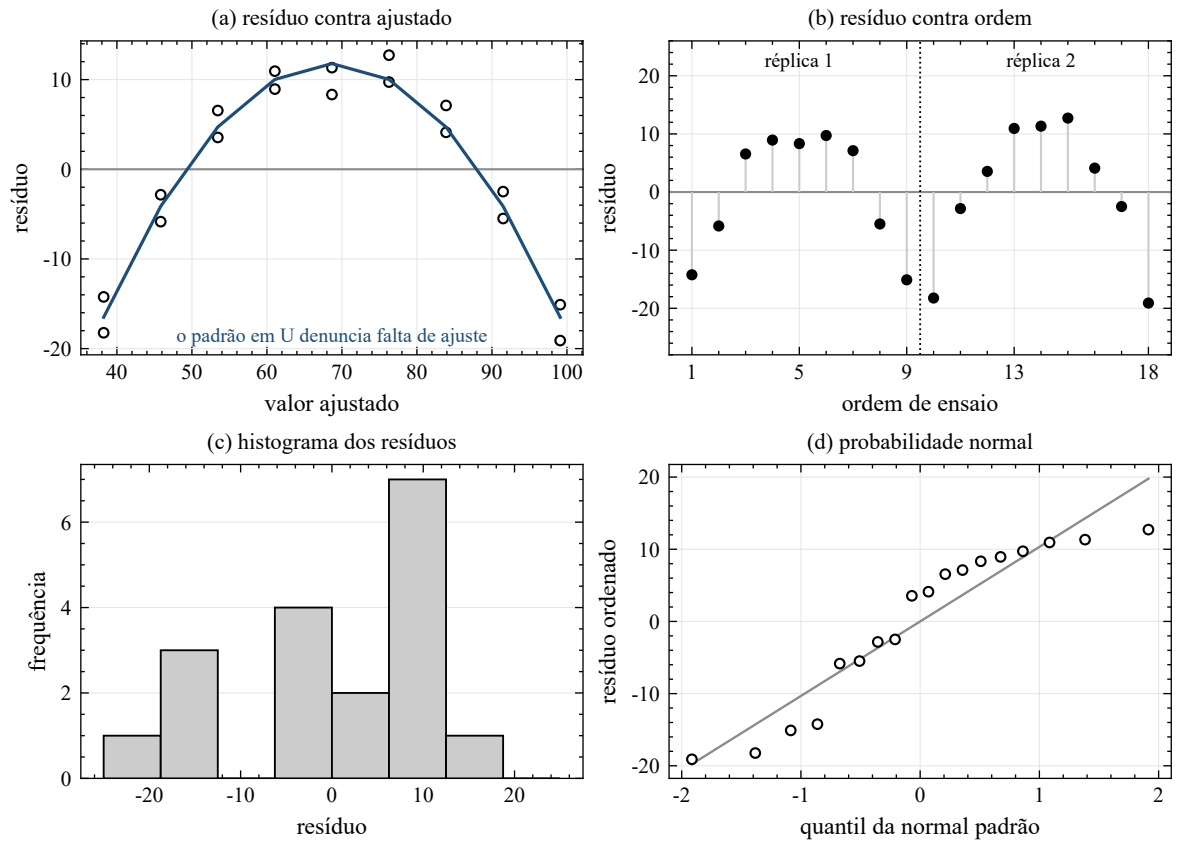


Figura 3. Quatro diagnósticos de resíduo para o modelo linear ajustado a `peixoto-lin-quad`. (a) resíduo contra valor ajustado, com um padrão em curva que denuncia falta de ajuste; (b) resíduo contra a ordem de execução, separado por réplica, sem tendência aparente; (c) histograma dos resíduos; (d) gráfico de probabilidade normal, com os pontos alinhados sobre a reta de referência.

O painel (a) da Figura 3 é o mais informativo dos quatro para este conjunto: o resíduo contra o valor ajustado exibe um padrão sistemático em curva, positivo no centro da faixa e negativo nas extremidades, em vez da dispersão sem padrão que um modelo adequado produziria. Esse formato é a assinatura visual de falta de ajuste, retomada com o teste formal na Seção 13: o modelo linear é sistematicamente incapaz de acompanhar a curvatura real da resposta. O painel (b), resíduo contra a ordem de execução, não mostra tendência entre a primeira e a segunda réplica, o que sustenta a hipótese de variância constante ao longo do experimento. Os painéis (c) e (d), histograma e gráfico de probabilidade normal, são coerentes com resíduos de distribuição aproximadamente simétrica, ainda que a amostra de dezoito pontos seja pequena para uma avaliação forte de normalidade. É importante notar que um padrão como o do painel (a) invalida a interpretação dos testes de significância que assumem forma funcional correta, ainda que os painéis (b) a (d) não acusem problema algum: os quatro diagnósticos respondem a perguntas diferentes, e nenhum deles isolado substitui os demais.

13 Falta de ajuste e erro puro

Quando existem réplicas genuínas nos mesmos pontos experimentais, o resíduo admite uma segunda decomposição, independente da decomposição da Equação (5):

$$\mathrm{SQ_r} = \mathrm{SQ_{faj}} + \mathrm{SQ_{ep}}, \qquad F_{\mathrm{faj}} = \frac{\mathrm{MQ_{faj}}}{\mathrm{MQ_{ep}}}. \tag{11}$$

A soma de quadrados de erro puro, $\mathrm{SQ_{ep}}$, mede a dispersão interna aos pontos replicados, e

independe inteiramente da forma funcional escolhida para o modelo, porque é calculada apenas a partir da diferença entre réplicas de um mesmo ponto. A soma de quadrados de falta de ajuste, $\mathrm{SQ}_{\mathrm{faj}}$, mede o quanto as médias previstas se afastam das médias observadas nesses mesmos pontos, e é a única das duas parcelas que responde à escolha do modelo. Um valor grande de F_{faj}, com p pequeno, é evidência de que a forma funcional do modelo é inadequada, independentemente de quão alto seja R^2.

Exemplo de aplicação. Dois usos do teste de falta de ajuste

A Tabela 4 retoma o conjunto `peixoto-lin-quad` sob os dois modelos já discutidos neste caderno, linear e quadrático, ajustados aos mesmos dezoito pontos.

Tabela 4. Falta de ajuste e erro puro em `peixoto-lin-quad`, modelo linear contra modelo quadrático.

Modelo	R^2	GL faj.	$\mathrm{MQ}_{\mathrm{faj}}$	F_{faj}
Linear	0,777873	7	276,9417	55,4
Quadrático	0,993461	6	2,23254	0,447

Em ambos os casos, $\mathrm{SQ}_{\mathrm{ep}} = 45$ e $\mathrm{MQ}_{\mathrm{ep}} = 5$: o erro puro é propriedade das réplicas, e não muda com o modelo. O que muda é a razão $F_{\mathrm{faj}} = \mathrm{MQ}_{\mathrm{faj}}/\mathrm{MQ}_{\mathrm{ep}}$, que cai de 55,4 no modelo linear, com $p \approx 1{,}10 \times 10^{-6}$ contra o quantil $F(7, 9)$, para 0,447 no quadrático, com $p = 0{,}830703$: nenhuma evidência de falta de ajuste remanescente. O ganho de R^2, de 0,78 para 0,99, é consequência da mesma correção, mas é o teste de falta de ajuste, e não o valor de R^2 isoladamente, que permite afirmar com rigor estatístico que o modelo quadrático é necessário.[a]

Um segundo exemplo, agora com falta de ajuste de fato detectada, vem do conjunto `origin-ccd`, uma composição central de dois fatores em dois blocos. A Tabela 5 reproduz o trecho relevante do relatório.

Tabela 5. Falta de ajuste e erro puro no relatório de `origin-ccd`.

Fonte	SQ	GL	MQ
Falta de ajuste	361,3125	6	60,21875
Erro puro	37,33333	4	9,33333

A razão resulta em $F_{\mathrm{faj}} = 6{,}45201$, com $p = 0{,}04628$: abaixo do limiar convencional de 5%, e portanto evidência de que o modelo puramente linear é insuficiente para essa superfície. É exatamente esse tipo de resultado que motiva a passagem para modelos com termos quadráticos e para o planejamento em composição central, tema do Caderno 4.

[a] A soma de quadrados da regressão do modelo quadrático recalculada sem arredondamento intermediário vale 8.871,604762, o que produz $R^2 = 0{,}993461$; a planilha original chega a 0,993459 ao arredondar a coluna de valores ajustados antes de somar os quadrados. A diferença, da ordem de 10^{-6}, ilustra por que o acúmulo de arredondamentos intermediários deve ser evitado em cálculos de soma de quadrados.

14 PRESS e o R^2 previsto

Todas as medidas discutidas até aqui, R^2, R^2_{aj} e os testes de significância, avaliam o ajuste do modelo aos mesmos dados que o estimaram. Um modelo pode ajustar-se muito bem aos pontos usados na sua própria construção e ainda assim prever mal uma observação nova, sintoma de excesso de ajuste. O antídoto é a validação cruzada deixe-um-de-fora: para cada observação i, o modelo é reajustado sem ela, produzindo uma previsão $\hat{y}_{(i)}$ que não usou aquele ponto, e o resíduo de previsão correspondente, $y_i - \hat{y}_{(i)}$, mede o quanto o modelo erraria ao prever um ponto que nunca viu. A soma dos quadrados desses resíduos é o PRESS,

$$\mathrm{PRESS} = \sum_{i=1}^{n} \left(y_i - \hat{y}_{(i)} \right)^2 . \tag{12}$$

Reajustar o modelo n vezes seria custoso, mas não é necessário: o resíduo de previsão relaciona-se ao resíduo comum por $y_i - \hat{y}_{(i)} = e_i/(1 - h_{ii})$, em que h_{ii} é o elemento diagonal da matriz de projeção $\mathbf{H} = \mathbf{X}(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top$, de modo que o PRESS é obtido em uma única passagem sobre o ajuste completo. A partir do PRESS define-se o R^2 previsto,

$$R^2_{\mathrm{prev}} = 1 - \frac{\mathrm{PRESS}}{\mathrm{SQ_T}}, \tag{13}$$

análogo ao R^2 da Equação (6), mas medido sobre previsões genuinamente fora da amostra. Diferentemente de R^2, o R^2 previsto pode ser negativo: isso ocorre quando o modelo prevê pior do que a simples média das observações, sinal inequívoco de sobreajuste.

Exemplo de aplicação. PRESS como antídoto contra o excesso de ajuste

A Tabela 6 retoma os mesmos dois conjuntos das Seções 7 e 9, agora sob a validação deixe-um-de-fora.

Tabela 6. PRESS e coeficiente de determinação previsto.

Conjunto	PRESS	R^2_{prev}
`origin-2x2`	127,1552	−0,68161
`aula-originpro`	20,61956	0,659325

Em `origin-2x2`, o R^2 previsto real é −0,68161: o modelo prevê pior do que simplesmente responder a média de todos os ensaios a qualquer ponto novo. O relatório de origem imprime esse valor como zero, porque o software trunca valores negativos de R^2 previsto antes de exibi-los; o valor real, e não o truncado, carrega a informação relevante, e deveria ser recalculado sempre que o relatório mostrar exatamente zero. Em `aula-originpro`, o R^2 previsto vale 0,659325, próximo do $R^2_{\mathrm{aj}} = 0{,}813693$ já apresentado na Tabela 2: um modelo cujo poder preditivo em pontos novos se aproxima do seu poder explicativo sobre os próprios dados de ajuste, o retrato de um modelo que generaliza. Os dois conjuntos desta tabela repetem, sob uma métrica diferente, exatamente o mesmo contraste já visto em R^2, em R^2_{aj} e nos testes de significância: três medidas independentes, três vezes a mesma conclusão.

---

15 Exemplo de aplicação: a velocidade de queima de uma pólvora

Exemplo de aplicação. $v = k \cdot P^a$, a lei de potência linearizada

A velocidade de queima v de uma pólvora, em milímetros por segundo, relaciona-se com a pressão de operação P, em libras por polegada quadrada, por uma lei de potência $v = k \cdot P^a$, com k e a constantes a determinar. Tomando o logaritmo decimal de ambos os lados, $\log_{10} v = \log_{10} k + a \log_{10} P$, o problema torna-se uma regressão linear simples nas variáveis transformadas $x = \log_{10} P$ e $y = \log_{10} v$, com $\beta_1 = a$ e $\beta_0 = \log_{10} k$ na forma não centrada. A Tabela 7 reproduz as dezoito observações.

Tabela 7. Dezoito observações de pressão e velocidade de queima, linearizadas por logaritmo decimal.

P	v	x	y	P	v	x	y
1	4,0	0,000000	0,602060	37	16,1	1,568202	1,206826
5	7,2	0,698970	0,857332	41	16,8	1,612784	1,225309
9	9,2	0,954243	0,963788	45	17,4	1,653213	1,240549
13	10,6	1,113943	1,025306	49	18,0	1,690196	1,255273
17	11,8	1,230449	1,071882	53	18,6	1,724276	1,269513
21	12,8	1,322219	1,107210	57	19,1	1,755875	1,281033
25	13,8	1,397940	1,139879	61	19,7	1,785330	1,294466
29	14,6	1,462398	1,164353	65	20,2	1,812913	1,305351
33	15,4	1,518514	1,187521	69	20,7	1,838849	1,315970

Ajustado o modelo centrado $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 (x - \bar{x})$ pela Equação (4), com $\bar{x} = 1{,}396684$, a Tabela 8 reúne os resultados completos do ajuste, já apresentados de forma parcial ao longo deste caderno.

Tabela 8. Resultados completos do ajuste de `peixoto-potencia`.

Grandeza	Valor
$\hat{\beta}_0$	1,139646
$\hat{\beta}_1$	0,391856
$\mathrm{SQ_R}$ (1 GL)	0,575784
$\mathrm{SQ_r}$ (16 GL)	0,000238
$\mathrm{SQ_T}$	0,576022
R^2	0,999587
s	0,003855
$F = \mathrm{MQ_R}/\mathrm{MQ_r}$	38.739,5

O coeficiente angular $\hat{\beta}_1 = 0{,}391856$ estima diretamente o expoente a da lei de potência. O intercepto, na forma centrada, é $\hat{\beta}_0 = \bar{y} = 1{,}139646$; para recuperar $\log_{10} k$ é necessário descentrar, $\log_{10} k = \hat{\beta}_0 - \hat{\beta}_1 \bar{x} = 0{,}592346$, do que resulta $k = 3{,}9115$. O modelo em unidades naturais é, portanto,

$$v = 3{,}9115 \cdot P^{0{,}391856},$$

com v em milímetros por segundo e P em libras por polegada quadrada. O ajuste praticamente satura o teto de R^2 que a precisão do instrumento de medição permite, e a Figura 1, já apresentada na Seção 3, mostra a nuvem, a reta e os resíduos deste mesmo ajuste, os últimos amplificados mil vezes para serem visíveis a olho nu. Este exemplo reúne, em um único conjunto de dados, praticamente todo o instrumental deste caderno: a estimação por mínimos quadrados, a decomposição da variância, o coeficiente de determinação, o teste F do modelo e os intervalos de confiança dos coeficientes, todos consistentes com o mesmo veredito de um ajuste excelente.

© 2026 Murilo Miguel Narciso. Todos os direitos reservados.
Instituto Militar de Engenharia, Rio de Janeiro.
Reprodução autorizada para fins didáticos, mantida a indicação de autoria.